

Précision de l'estimation de Jaccard

annexe expérimentale : variance, loi en $1/\sqrt{s}$, distance de Mash

TP JC2BIMMM

d'après la revue de C. Marchet et les articles cités

La question : quelle confiance dans $\hat{J}$?

On remplace des millions de k-mers par s **valeurs**, puis on estime $\hat{J} = x/s$ (x = nombre de positions concordantes).

Avec le **partition sketch**, les s cases sont **indépendantes** : chaque case concorde avec probabilité J (le vrai Jaccard). Autant de tirages « pile ou face ».



$$x = 5 \Rightarrow \hat{J} = 5/8$$

De combien $\hat{J}$ s'écarte-t-il de J ?

Le modèle binomial

Le nombre de concordances X suit une loi **binomiale** :

$$X \sim \mathcal{B}(s, J), \quad \hat{J} = \frac{X}{s}.$$

Sans biais : $\mathbb{E}[\hat{J}] = J$.

Variance :

$$\text{Var}(\hat{J}) = \frac{J(1-J)}{s}, \quad \sigma = \sqrt{\frac{J(1-J)}{s}}.$$


Loi de l'erreur

$$\varepsilon = O\left(\frac{1}{\sqrt{s}}\right)$$

Indépendante de la taille du génome
(Mash).

Diviser l'erreur par 2 $\Rightarrow$ multiplier s par 4.

L'erreur décroît en $1/\sqrt{s}$



En échelle log-log, une **droite de pente** $-\frac{1}{2}$: $\sigma \propto 1/\sqrt{s}$. La variance est maximale à $J = 0,5$.

IC à 95 % (approximation normale) :

$$\hat{J} \pm 1,96 \sqrt{\frac{\hat{J}(1 - \hat{J})}{s}}.$$

- La variance *absolue* est maximale à $J = 0,5$; mais en **relatif**, ce sont les **petits** J (génomomes éloignés) qui souffrent : signal faible $\Rightarrow$ il faut un s plus grand.
- Rappel (revue) : le proxy Jaccard se dégrade quand les ensembles sont *dissemblables* ou de *tailles très différentes* $\Rightarrow$ on lui préfère alors la *containment* (Jaccard de confinement).

De Jaccard à une distance : Mash

Mash convertit le Jaccard estimé j en une distance proche de $1 - \text{ANI}$:

$$D = -\frac{1}{k} \ln \frac{2j}{1+j} \quad (\text{Ondov et al. 2016})$$

Modèle de Poisson : la probabilité qu'un k-mer échappe à toute mutation (taux d) vaut e^{-kd} — d'où le lien entre fraction de k-mers partagés et distance.

L'erreur sur j (en $1/\sqrt{s}$) se **propage** à D .

Exemple chiffré (Mash)

$s = 1000$, $D = 0,05$:

erreur $< 0,0068$ avec probabilité 0,99.

Compresser : que coûte la précision ?

- **b-bit MinHash** (Li & König 2010) : ne garder que b bits par haché $\Rightarrow$ collisions *aléatoires* (proba $\approx 2^{-b}$); un estimateur **corrigé** retire ce biais, au prix d'un peu de variance — pour beaucoup moins de mémoire.
- **HyperMinHash** (Yu & Weber 2017) : exposant HLL (zéros de tête, $O(\log \log n)$ bits) + mantisse b -bit $\Rightarrow \sim 16$ bits/case; erreur relative ε avec $\sim \varepsilon^{-2}$ cases.
- **HyperLogLog** (Flajolet et al. 2007) : cardinalité à $\approx 1,04/\sqrt{m}$ (m registres).

Compromis

À **mémoire égale**, plus de cases $\Rightarrow$ variance plus faible. Les collisions de la compression $\Rightarrow$ léger **biais** (surestimation), atténué par de plus gros sketches.

- **Broder** (1997). *On the resemblance and containment of documents* — MinHash.
- **Li & König** (2010). *b-Bit Minwise Hashing* — WWW.
- **Flajolet, Fusy, Gandouet, Meunier** (2007). *HyperLogLog* — AofA.
- **Ondov et al.** (2016). *Mash : fast genome and metagenome distance estimation using MinHash* — Genome Biology.
- **Yu & Weber** (2017). *HyperMinHash* — arXiv :1710.08436.
- **Baker & Langmead** (2019). *Dashing : fast and accurate genomic distances with HyperLogLog* — Genome Biology.

Synthèse : revue de C. Marchet, kamimrcht.github.io/webpage/sketch.html.

La précision se résume à une loi :

$$\sigma(\hat{J}) = \sqrt{J(1-J)/s}$$

plus de cases, moins d'erreur — en $1/\sqrt{s}$.